Proyecto aplicado: Reconstrucción y regularización en imágenes tomográficas

Métodos Computacionales, S2 2026

1 Introducción

Una tomografía computada permite observar el interior de un objeto sin abrirlo a partir de mediciones obtenidas mediante rayos X. En el modelo simplificado que utilizaremos en este trabajo, un emisor colimado genera una familia de rayos paralelos que atraviesan una sección del objeto y son registrados por un arreglo lineal de detectores ubicado del lado opuesto. Cada detector mide cuánta intensidad logra atravesar el objeto a lo largo de uno de esos rayos. Los materiales con mayor coeficiente de atenuación reducen más la intensidad del haz, mientras que aquellos con menor coeficiente de atenuación permiten que llegue una intensidad mayor al detector.

Para una orientación dada θ se adquiere un conjunto de mediciones correspondientes a rayos paralelos que atraviesan distintas regiones de una sección de corte. Al cambiar el ángulo θ, el sistema observa el mismo objeto desde una nueva dirección. Repitiendo este procedimiento para múltiples orientaciones se obtiene la información necesaria para intentar reconstruir la distribución de atenuación en el interior de la sección.

Si I_0 es la intensidad emitida por uno de los rayos e I es la intensidad registrada por el detector correspondiente después de atravesar el objeto, un modelo simplificado relaciona ambas cantidades mediante:

$$I = I_0 \exp\left(-\int \mu(r)dr\right)$$

Aquí, $\mu(r)$ describe la atenuación del material en cada punto y r representa el recorrido del rayo a través del objeto. Al tomar logaritmos se obtiene una medición lineal en la atenuación:

$$-\log(I/I_0) = \int \mu(r)dr$$

En este trabajo práctico estudiaremos una versión discreta y simplificada del problema de reconstrucción de una imagen tomográfica. Representaremos una sección del objeto mediante una imagen pequeña, dividida en píxeles. Cada rayo producirá una medición asociada a la atenuación acumulada a lo largo de su recorrido y el conjunto completo de mediciones podrá escribirse como un sistema lineal de la forma $b = Ax$. El vector x representará la imagen desconocida, cada fila de A describirá cómo un rayo atraviesa los distintos píxeles y b contendrá las mediciones del escáner.

Comenzaremos simulando la adquisición de una tomografía ideal. Luego estudiaremos qué ocurre cuando la cantidad de proyecciones no alcanza para determinar una imagen de manera única. Más adelante incorporaremos ruido, formularemos la reconstrucción como un problema de mínimos cuadrados e implementaremos métodos iterativos de optimización. Finalmente, incorporaremos una penalización de suavidad al problema de reconstrucción y estudiaremos el compromiso entre fidelidad a las mediciones y reducción del ruido.

2 Objetivos

Esperamos que logren:

- representar una imagen como un vector y una adquisición tomográfica como una transformación lineal;
- construir e interpretar una matriz de proyección a partir de un conjunto de rayos;
- relacionar la cantidad y orientación de las mediciones con el rango y el espacio nulo de una matriz;
- formular una reconstrucción con ruido como un problema de mínimos cuadrados;
- interpretar la solución de mínimos cuadrados como una proyección ortogonal;
- reconocer el rol de la matriz simétrica $A^T A$ y de sus valores propios;
- implementar gradiente descendiente y el método de Newton para minimizar funciones cuadráticas;
- construir matrices de diferencias para medir la falta de suavidad de una imagen;
- formular una reconstrucción regularizada mediante una penalización cuadrática de las diferencias entre píxeles vecinos;
- analizar el compromiso entre fidelidad a las mediciones, reducción de ruido y preservación de detalles.

3 Temario

- Imágenes como vectores
- Transformaciones lineales
- Sistemas lineales
- Rango y espacio nulo
- Mínimos cuadrados
- Proyecciones ortogonales
- Matrices simétricas y Formas cuadráticas
- Valores propios
- Gradiente descendiente y Método de Newton
- Regularización
- Visualización en Python

4 Modelo de adquisición tomográfica

4.1 Geometría de adquisición

En este trabajo reconstruiremos una única sección bidimensional del objeto, como un corte visto desde arriba. La imagen desconocida se representará mediante una función de atenuación $\mu(u, v)$ definida sobre ese plano. Un valor alto de μ representa una región que atenúa fuertemente los rayos X; un valor bajo representa una región más transparente.

4.2 Parametrización de los rayos

Representaremos cada punto del plano mediante el vector $p = [u, v]^T \in \mathbb{R}^2$. Para una orientación θ, definimos el vector normal unitario $n_\theta = [\cos\theta, \sin\theta]^T$. La ecuación central de esta parametrización es $n_\theta^T p = u\cos\theta + v\sin\theta = s$. El producto interno es la proyección de p sobre n_θ. Al fijarla en s, estamos seleccionando todos los puntos de una recta perpendicular a n_θ:

$$l_{\theta,s} = \{p \in \mathbb{R}^2 : n_\theta^T p = s\}$$

Por lo tanto, θ fija la orientación de una familia de rayos paralelos y s selecciona uno de ellos. Basta considerar $\theta \in [0, \pi)$.

4.3 Las mediciones y el sinograma

Cada detector registra la atenuación acumulada a lo largo de un rayo. Para un ángulo fijo θ, el conjunto de mediciones obtenido en las distintas posiciones s se denomina proyección. Si utilizamos K ángulos y q posiciones de detector, organizaremos todas las mediciones en una matriz $S \in \mathbb{R}^{K\times q}$ denominada sinograma. Para formular posteriormente el sistema lineal, recorreremos la matriz S por filas y almacenaremos sus Kq mediciones en un único vector $b \in \mathbb{R}^m$, con $m = Kq$.

4.4 Discretización matricial

Representaremos la imagen tomográfica reconstruida mediante una matriz $X \in \mathbb{R}^{n\times n}$. Para trabajar con álgebra lineal, apilaremos sus filas en un vector $x \in \mathbb{R}^{n^2}$. Una adquisición con K ángulos y q posiciones de detector produce $m = Kq$ mediciones. La relación entre la imagen X y estas mediciones se representa mediante una matriz $A \in \mathbb{R}^{m\times n^2}$. La entrada a_{rj} indica la longitud del tramo del rayo r que atraviesa el píxel j. La medición producida por el rayo r es $b_r = \sum_{j=0}^{n^2-1} a_{rj}x_j = (Ax)_r$. Al reunir todas las mediciones obtenemos el sistema lineal $b = Ax$.

4.5 Un primer modelo binario

En este primer modelo, los píxeles con los que contribuye un rayo se seleccionan únicamente a partir de sus centros. Identificamos cada píxel mediante sus índices (i, j). Dados tres enteros α, β y s, diremos que el centro de un píxel pertenece al rayo discreto cuando $\alpha i + \beta j = s$. El par (α, β) determina la orientación de la familia y s selecciona uno de sus rayos. Para cada rayo discreto r, la fila a_r de A contiene un 1 en las posiciones de los píxeles seleccionados y un 0 en las restantes.

5 Condiciones de entrega y modalidad de aprobación

La entrega deberá realizarse en un único archivo comprimido en formato .zip. El archivo deberá contener un notebook de Jupyter por ejercicio (ya ejecutado). Los notebooks deben incluir el código, las explicaciones, los gráficos solicitados y las respuestas conceptuales. También se deberá entregar una presentación en formato pdf que resuma las soluciones del trabajo práctico.

Las entregas estarán habilitadas desde el martes 15 de septiembre y podrán realizarse en cualquier momento hasta el lunes 2 de noviembre a las 23:59.

La calificación se dividirá en dos componentes:

- la presentación entregada tendrá un valor de hasta 30 puntos;
- la instancia oral tendrá un valor de hasta 70 puntos.

Para aprobar el trabajo práctico será necesario aprobar la instancia oral sin considerar la bonificación por entrega anticipada.

6 Ejercicios

1. Una imagen como matriz y como vector

Utilizaremos inicialmente una imagen de 8×8 píxeles, representada mediante la matriz $X_{\text{fantoma}} \in \mathbb{R}^{8\times 8}$. Crear en Python la matriz de prueba utilizando los valores indicados en el enunciado original.

a) Visualizar X_{fantoma} mediante `plt.imshow`, utilizando una escala de grises con su referencia.

b) Convertir X_{fantoma} en el vector $x_{\text{fantoma}} \in \mathbb{R}^{64}$ mediante `reshape(-1)`.

c) Recuperar la matriz original a partir de x_{fantoma} y verificar numéricamente que ambas representaciones contienen la misma información.

d) Explicar qué magnitud representa el valor de una componente x_k en el modelo tomográfico.

e) Modificar un píxel de X_{fantoma} y localizar qué componente x_k cambia. Expresar mediante una ecuación la relación entre los índices (i, j) del píxel y su posición k en el vector.

2. Simulación de un único rayo binario

Utilizaremos el fantoma del ejercicio anterior para simular una medición del modelo binario.

a) Implementar la función `mascara_rayo(n, direccion, s)`, que devuelva una matriz $M_r \in \{0, 1\}^{n\times n}$ con un 1 en los píxeles seleccionados y un 0 en los restantes.

b) Visualizar las máscaras para las direcciones (1,0), (0, 1), (1, 1), (1, -1) y (2, 1), utilizando los desplazamientos $s = 3, 5, 7, 0, 8$.

c) Para cada máscara, calcular la medición $b_r = \sum_{i,j}(M_r)_{ij}(X_{\text{fantoma}})_{ij}$ mediante un producto componente a componente.

d) Explicar por qué dos rayos con orientaciones diferentes pueden producir el mismo valor de medición aunque seleccionen distintos píxeles.

3. Construcción de la matriz de proyección binaria

Continuaremos utilizando la matriz X_{fantoma} y su versión vectorizada x_{fantoma}.

a) Implementar la función `matriz_proyeccion(n, direcciones)` para ordenar y construir las máscaras, y agregarlas como filas de A.

b) Hacer que la función devuelva también una lista con el par $((\alpha, \beta), s)$ asociado a cada fila de A.

c) Aplicar la función con $n = 8$ y direcciones = [(1,0), (0, 1)]. Verificar que se obtienen 16 rayos y que $A \in \mathbb{R}^{16\times 64}$.

d) Explicar qué representa una fila de A y qué representa una columna. Visualizar la matriz y explicar por qué contiene una gran cantidad de ceros.

e) Calcular las mediciones $b = Ax_{\text{fantoma}}$. Verificar las componentes y graficar los bloques.

4. ¿Es posible reconstruir la imagen de manera única?

Analizaremos el rango y el espacio nulo de distintas matrices de proyección.

a) Considerar $A \in \mathbb{R}^{m \times 64}$. Utilizando el teorema de rango y nulidad, determinar qué condición debe cumplir rango(A) para que la imagen pueda reconstruirse de manera única. Explicar qué ocurre si existe $Av = 0$.

b) Construir las matrices A_2, A_4 y A_7 utilizando conjuntos de direcciones específicas. Informar sus dimensiones, su rango, la dimensión de su espacio nulo y si permite determinar una imagen única.

c) Para A_4, utilizar SVD para encontrar un vector nulo v y verificar $\|A_4 v\| \approx 0$. Visualizar e interpretar qué información resulta invisible para A_4.

5. Reconstrucción en condiciones ideales

Trabajaremos con mediciones ideales, sin ruido.

a) Para cada $k \in \{2, 4, 7\}$, generar $b_k = A_k x_{\text{fantoma}}$ y resolver mediante mínimos cuadrados para obtener una reconstrucción $\hat{x}_k$.

b) Para cada reconstrucción, calcular el residuo r_k, su norma y el error relativo.

c) Visualizar cada caso original y reconstruido y explicar por qué un residuo cercano a cero no garantiza que la imagen haya sido recuperada correctamente.

6. Mediciones con ruido y mínimos cuadrados

Agregaremos ruido y obtendremos mediciones perturbadas $b_\sigma = b_7 + \eta_\sigma$.

a) Fijar una semilla aleatoria y generar un vector de ruido escalado para $\sigma \in \{0, 0.01, 0.03, 0.06, 0.10\}$.

b) Utilizar mínimos cuadrados para obtener $\hat{x}_\sigma$ y registrar errores, visualizando las imágenes reconstruidas.

c) Analizar cómo cambia el error al aumentar σ, por qué el residuo deja de ser nulo y por qué aparecen valores negativos.

7. La reconstrucción como proyección ortogonal

Continuaremos utilizando A_7 y las mediciones con $\sigma = 0.06$.

a) Calcular el residuo $r_\sigma = b_\sigma - A_7 \hat{x}_\sigma$ y verificar que $\|A_7^T r_\sigma\| \approx 0$.

b) Explicar por qué esto indica que $A_7 \hat{x}_\sigma$ es la proyección ortogonal de b_σ sobre el espacio columna de A_7.

c) Explicar la diferencia entre las proyecciones tomográficas medidas por el escáner y la proyección ortogonal en mínimos cuadrados.

8. Mínimos cuadrados mediante métodos iterativos

Resolveremos utilizando $E(x) = \frac{1}{2}\|A_7 x - b_\sigma\|^2$.

a) Implementar funciones que calculen $E(x)$ y su gradiente $\nabla E(x)$. Construir $H = A_7^T A_7$ y verificar que es simétrica.

b) Implementar gradiente descendiente y registrar el costo.

c) Calcular μ_{max} de H, probar tasas de aprendizaje α y describir convergencia.

d) Implementar el método de Newton y verificar que alcanza la solución en una sola iteración.

e) Comparar las reconstrucciones obtenidas mediante gradiente descendiente, Newton y métodos directos.

9. Reconstrucción tomográfica con regularización cuadrática

El objetivo será estudiar cómo cambia la reconstrucción al modificar el ruido y la intensidad de la regularización construyendo una matriz D.

a) Implementar `matriz_diferencias(n)` y verificar dimensiones.

b) Crear un vector constante $x_{\text{constante}}$ y verificar que $Dx_{\text{constante}} = 0$.

c) Interpretar qué mide cada término de $J_{\sigma,\lambda}(x) = \frac{1}{2}(\|A_7 x - b_\sigma\|^2 + \lambda\|Dx\|^2)$.

d) Generar mediciones para $\sigma \in \{0, 0.10, 0.20\}$.

e) Adaptar gradiente descendiente para minimizar $J_{\sigma,\lambda}$ explorando combinaciones de σ y λ.

f) Seleccionar una tasa de aprendizaje e implementar un criterio de parada.

g) Graficar el error relativo e_t en función de iteraciones.

h) Organizar las reconstrucciones finales en una grilla.

i) Resumir errores en una tabla o mapa de calor.

j) Analizar en qué casos la regularización mejoró la reconstrucción y el efecto de regularización excesiva.

10. Aplicación final: reconstruir una imagen desconocida

Utilizaremos una matriz de proyección basada en la geometría de los rayos. Los datos se encuentran en el archivo final.

a) Cargar los datos y determinar K y q. Verificar dimensiones de A y b.

b) Organizar las mediciones en una matriz S y visualizar el sinograma.

c) Adaptar `matriz_diferencias(n)` para construir D como matriz dispersa.

d) Obtener reconstrucción sin regularización ($\lambda = 0$) usando gradiente descendiente.

e) Obtener reconstrucciones regularizadas minimizando $J_\lambda(x)$ explorando diferentes valores de λ.

f) Registrar iteraciones, residuos, medida de variación y comparar con estimación de ruido.

g) Elegir la reconstrucción más adecuada y justificar.

11. Reflexión final

Responder brevemente:

a) ¿Por qué la reconstrucción tomográfica se considera un problema inverso?

b) ¿Cómo puede determinarse, a partir de A, si las mediciones permiten recuperar una única imagen?

c) ¿Cómo afecta el ruido al sistema de ecuaciones?

d) ¿Qué supuesto sobre la imagen introduce el término $\|Dx\|^2$?

e) Comparar el método de mínimos cuadrados directo, gradiente descendiente y Newton.

f) Elaborar una síntesis que conecte el modelo $b = Ax$ con el rango, espacio nulo, proyecciones ortogonales, mínimos cuadrados y regularización.